基于“预测然后优化”的飞行区保障车辆调度优化

2026 年 3 月 30 日

1 Introduction

2 Problem formulation

下表 1是建模所用到的参数。

表 1: GSE 调度建模所用到的记号

符号	描述	定义域
集合		
$\mathcal{F}$	航班集合，$n \in \mathcal{F}$	$\{1, \ldots, F\}$
$\mathcal{N}$	任务节点集合，$i, j, h \in \mathcal{N}$	$\{1, \ldots, N\}$
$\mathcal{V}$	物理网络节点集合（包含始发/终到车库 $0, N+1$）	$\mathcal{N} \cup \{0, N+1\}$
$\mathcal{K}$	有人车辆集合，$k \in \mathcal{K}$	$\{1, \ldots, K\}$
$\mathcal{N}_n$	属于航班 n 的任务集	$\mathcal{N}_n \subset \mathcal{N}$
惩罚系数		
π	航班离港延误的单位成本	$\mathbb{R}_+$
α	车等飞机的单位成本	$\mathbb{R}_+$
β	飞机等车的单位成本	$\mathbb{R}_+$
业务参数		
τ_{ij}	有人车从节点 i 到 j 的行驶时间	
s_i	任务 i 的作业时长	
d_n^0	航班 n 的计划离港时间	
M	一个足够大的正数	
$\hat{a}_n$	航班 n 的预测到达时间 (ATA)	
a_n	航班 n 的实际到达时间	
决策变量		
x_{ij}^k	有人车 k 从 i 行驶到 j	$\{0, 1\}$
z_i^k	有人车 k 执行 i 处的任务	$\{0, 1\}$
t_i	任务 i 开始作业的时刻	$\mathbb{R}_+$
r_i^k	有人车 k 到达任务节点 i 的时刻	$\mathbb{R}_+$
w_i	车辆在 i 处等待飞机的时间	$\mathbb{R}_+$
v_i	飞机在 i 处等待车辆的时间	$\mathbb{R}_+$
y_n	航班 n 的离港延误时间	$\mathbb{R}_+$

对于车辆集合 $\mathcal{K}$ 其构成如下：

$$\mathcal{K} = \mathcal{K}_b \cup \mathcal{K}_o$$

其中 $\mathcal{K}_b$ 是行李车集合，$\mathcal{K}_o$ 是牵引车集合。我们先不考虑牵引车。

对于任务节点集合 $\mathcal{N}$，有如下关系：

$$\mathcal{N} = \mathcal{N}^{\text{arr}} \cup \mathcal{N}^{\text{dep}} \cup \mathcal{N}^{\text{push}}$$

其中 $\mathcal{N}^{\text{arr}}$ 和 $\mathcal{N}^{\text{dep}}$ 分别代表了到达后和起飞前的行李与货物装卸任务集合，$\mathcal{N}^{\text{push}}$ 是推出任务集合。单个航班 n 的过站任务集合由 $\mathcal{N}_n$ 表示。对于 $\forall n \in \mathcal{F}$ 满足如下关系：

$$\bigcup_{n \in \mathcal{F}} \mathcal{N}_n = \mathcal{N}$$

$$\mathcal{N}_n \cap \mathcal{N}_{n'} = \varnothing,\ \forall n \neq n'$$

$$\mathcal{N}^{\text{arr}} \cap \mathcal{N}^{\text{dep}} = \varnothing$$

$$\|\mathcal{N}_n \cap \mathcal{N}^{\text{arr}}\| = \|\mathcal{N}_n \cap \mathcal{N}^{\text{dep}}\| = \|\mathcal{N}_n \cap \mathcal{N}^{\text{push}}\| = 1$$

GSE 联合调度优化问题建模如下，其目标函数为最小化航班所有起飞延误的和车机相互等待的总成本之和：

$$\min \quad \sum_{n \in \mathcal{F}} \pi y_n + \sum_{i \in \mathcal{N}} \alpha w_i + \sum_{i \in \mathcal{N}^{\text{arr}}} \beta v_i \tag{1}$$

考虑到最严重的问题是飞机起飞延误，而地面保障车辆的晚到相比于早到更有可能导致后续的延误，因此三个参数满足 $\pi > \beta > \alpha$。

约束条件有：

流守恒约束和车辆资源约束：

$$\sum_{j \in \mathcal{V} \setminus \{i\}} x_{ij}^k = \sum_{j \in \mathcal{V} \setminus \{i\}} x_{ji}^k, \quad \forall i \in \mathcal{V}, \forall k \in \mathcal{K} \tag{2}$$

$$\sum_{k \in \mathcal{K}} \sum_{i \in \mathcal{N}} x_{0i}^k \leq K \tag{3}$$

$$\sum_{k \in \mathcal{K}} \sum_{i \in \mathcal{N}} x_{0i} = \sum_{k \in \mathcal{K}} \sum_{j \in \mathcal{N}} x_{j,N+1} \tag{4}$$

车辆任务的流转约束：

$$r_j^k \geq t_i + s_i + \tau_{ij} - M \cdot (1 - x_{ij}^k), \quad \forall i \in \mathcal{V} \setminus \{N+1\}, \forall j \in \mathcal{V} \setminus \{0\} \tag{5}$$

$$t_j \geq r_j^k - M \cdot (1 - x_{ij}^k), \quad \forall i \in \mathcal{V} \setminus \{N+1\}, \forall j \in \mathcal{V} \setminus \{0\} \tag{6}$$

任务先后顺序约束（飞机降落后卸货—装货–离港的顺序不能变）：

$$t_i \geq \hat{a}_n, \quad \forall n \in \mathcal{F}, \forall i \in \mathcal{N}_n \cap \mathcal{N}^{\text{arr}} \tag{7}$$

$$t_i \geq r_i^k, \quad \forall i \in \mathcal{N}, \forall k \in \mathcal{K} \tag{8}$$

$$t_i \geq t_i + s_i, \quad \forall n \in \mathcal{F}, \forall i \in \mathcal{N}_n \cap \mathcal{N}^{\text{arr}}, \forall j \in \mathcal{N}_n \cap \mathcal{N}^{\text{dep}} \tag{9}$$

这些约束说明，作业开始时间必须晚于预测到达的时间和车辆到达的时间，而且同航班的装货任务必须在卸货任务之后。

延误决策变量定义：

$$w_i \geq t_i - r_i^k, \quad \forall i \in \mathcal{N}, \forall k \in \mathcal{K} \tag{10}$$

$$v_i \geq t_i - \hat{a}_n, \quad \forall n \in \mathcal{F}, \forall i \in \mathcal{N}_n \cap \mathcal{N}^{\text{arr}} \tag{11}$$

$$y_n \geq t_i + s_i - d_n^0, \quad \forall n \in \mathcal{F}, \forall i \in \mathcal{N}_n \cap \mathcal{N}^{\text{dep}} \tag{12}$$

以及所有的决策变量的取值：

$$\begin{aligned} & x_{ij}^k \in \{0,1\}, \quad \forall i,j \in \mathcal{V}, \forall k \in \mathcal{K} \\ & r_i^k, t_i, w_i, v_i \geq 0, \quad \forall i \in \mathcal{V}, \forall k \in \mathcal{K} \\ & y_n \geq 0, \quad \forall n \in \mathcal{F} \end{aligned} \tag{13}$$

这是一个带有未知参数的混合整数规划问题 (MIP)。在约束条件中，未知参数包括了飞机的实际到达时刻 a_n，起飞时刻 d_n。在下一节中我们将给出参数的预测方式。

3 Methodology

3.1 标准 SPO 框架的局限性

本节介绍基于 SPO 的预测-决策方法。在一般的 SPO 范式中，预测参数 $\hat{c}$ 的过程可以如下图 1所示：

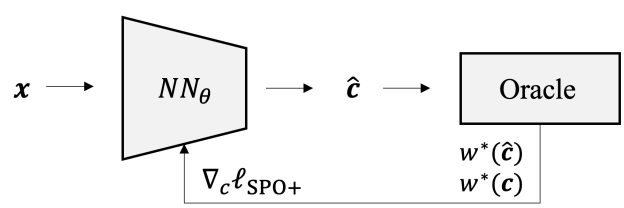

图 1: SPO 训练流程

具体而言，输入特征 x 经过预测器（假如是一个参数为 θ 的神经网络）后输入预测向量 $\hat{c}$，随后构造一个新的、被扰动的成本向量 $(2\hat{c} - c)$ 并调用求解器求解如下的优化问题：

$$w^*(2\hat{c} - c) = \arg\min_{w \in S} (2\hat{c} - c)^\top w \tag{14}$$

并且与同样调用求解器得到的真实参数下的最优决策 $w^*(c) = \arg\min_{w \in S} c^\top w$ 相对比，计算 $\ell_{\text{SPO+}}(\hat{c}, c)$ 并进行梯度回传以更新预测器参数 θ，指引正确的参数更新方向，从而接近最优决策。

这样标准的 SPO 范式所能够解决的问题是如下的线性优化问题 (LP)：

$$\begin{aligned} \min_{w} \quad & c^\top w \\ \text{s.t.} \quad & w \in S \end{aligned} \tag{15}$$

其中决策 w 的可行域 S 是一个非空的、紧的凸集，并且是固定的 [Elmachtoub and Grigas, 2022]，只有目标函数包含待预测参数 c。若 c 包含在约束条件中，则会导致可行域 S 会随着预测值的变化而变化。

具体而言，对我们上一节中的模型，可以写成如下的形式：

$$\min_{\boldsymbol{w}\geq\boldsymbol{0}} \quad \boldsymbol{c}^\top \boldsymbol{w}$$

$$\text{s.t.} \quad \boldsymbol{G}\boldsymbol{w} \leq \boldsymbol{h} \tag{16}$$

$$\boldsymbol{Q}\boldsymbol{w} \leq \boldsymbol{d}(\hat{a}_n) \tag{17}$$

其中 $\boldsymbol{c}$ 和 $\boldsymbol{w}$ 分别是惩罚系数和决策变量的向量，而 (16)代表了所有和 ATA $\hat{a}_n$ 无关的约束条件，(17)代表了和 $\hat{a}_n$ 有关的约束条件，$\boldsymbol{d}(\hat{a}_n)$ 是关于 $\hat{a}_n$ 的仿射函数。我们写出其对偶形式：

$$\max_{\boldsymbol{\lambda},\boldsymbol{\mu}\geq\boldsymbol{0}} -\boldsymbol{h}^\top\boldsymbol{\mu} - \boldsymbol{d}(\hat{a}_n)^\top\boldsymbol{\lambda} \tag{18}$$

$$\text{s.t.} -\boldsymbol{G}^\top\boldsymbol{\mu} - \boldsymbol{Q}^\top\boldsymbol{\lambda} \leq \boldsymbol{c} \tag{19}$$

其中 $\boldsymbol{\lambda}$ 和 $\boldsymbol{\mu}$ 为对偶变量，$\boldsymbol{\lambda}$ 对应了航班时间的动态约束，可以理解为 $\hat{a}_n$ 若发生一个微小的扰动，目标函数的变化量；而 $\boldsymbol{\mu}$ 对应了静态的资源约束，可以理解为如果车辆数量发生了个微小的扰动（这也是松弛成 LP 的另一个问题，就是车辆数不会发生一个“微小的扰动”），目标函数的变化量。现在对偶函数的可行域中没有 $\hat{a}_n$，是固定的，这看起来完全符合 SPO 的形式。但是这不能说明这样求解出来的 $\boldsymbol{\lambda}$ 和 $\boldsymbol{\mu}$ 就能够求得原来的调度方案，综合原问题和对偶问题，原因如下：

- **原问题中，解不一定可行：** SPO+ 的目标是训练一个预测模型，使得产生的决策 $w(\hat{a}_n)$ 在真实参数下的 Regret 最小，而在约束中约束含有 $\hat{a}_n$，导致了 $w(\hat{a}_n)$ 不一定可行；
- **对偶问题最优 ≠ 原问题最优：** 对偶问题最优解是原问题的一个下界，不一定满足强对偶性，除非松弛后 LP 的最优解也是整数，这要求原问题的约束满足全幺模性 [Hoffman, 1976, Dey et al., 2010]，即约束矩阵的任意子方阵的行列式只能为 0 或者 ±1，而原问题约束中含有大 M，肯定不满足。

3.2 基于惩罚项的两步 SPO 框架

受Hu et al. [2023] 的启发，针对本优化模型进行 $\hat{a}_n$ 的预测，我们提出了如下的 2-step SPO 框架。首先，我们构建一个预测器来预测到达时间：

$$\hat{\boldsymbol{a}} = f(\boldsymbol{u};\theta) \tag{20}$$

其中 f 是预测器（比如一个 NN），而 $\boldsymbol{u}$ 是输入特征，θ 是可训练的预测器参数。定义成本函数 $\Phi(\boldsymbol{\xi})$ 为：

$$\Phi(\boldsymbol{\xi}) = \boldsymbol{c}^\top\boldsymbol{\xi} = \sum_{n\in\mathcal{F}} \pi y_n + \sum_{i\in\mathcal{N}} \alpha w_i + \sum_{i\in\mathcal{N}^{\text{arr}}\cup\mathcal{N}^{\text{fuel}}} \beta v_i \tag{21}$$

在输入特征并且输出代表所有航班的预计到达时间的预测向量 $\hat{\boldsymbol{a}}$ 后，我们进入 Step 1，求解如下优化问题：

$$(\boldsymbol{x}^*,\boldsymbol{\xi}^*) = \arg\min_{\boldsymbol{x},\boldsymbol{\xi}} \quad \Phi(\boldsymbol{\xi}) \tag{22}$$

$$\text{s.t} \quad (\boldsymbol{x},\boldsymbol{\xi}) \in \Omega \tag{23}$$

$$\boldsymbol{G}\boldsymbol{\xi} \leq \boldsymbol{h} + \boldsymbol{M}\odot(\boldsymbol{1}-\boldsymbol{x}) \tag{24}$$

$$\boldsymbol{Q}\boldsymbol{\xi} \geq \boldsymbol{d}(\hat{\boldsymbol{a}}) \tag{25}$$

这里 $\boldsymbol{x} \in \{0,1\}^{\|\mathcal{K}\cup\mathcal{K}'\|\times\|\mathcal{V}\|^2}$ 是所有二元变量的空间，而 $\boldsymbol{\xi} = [\boldsymbol{t}, \boldsymbol{r}, \boldsymbol{r}', \boldsymbol{w}, \boldsymbol{v}, \boldsymbol{y}]$ 是所有连续变量的向量。约束 (23)是所有流守恒和物理路径约束，而 (24)是所有含有大 M 的约束，(25)是含有预测参数的约束。通过求解这一优化问题得到最优的车辆调度方案 $\boldsymbol{x}^*(\hat{\boldsymbol{a}})$，这就是 Step 1 的结果，得到了一个提前的排班结果，准备在第二天执行。

接下来进入 Step 2，在此阶段，参数 $\boldsymbol{a}$ 被揭露 [Hu et al., 2023]，我们固定 Step 1 得到的 $\boldsymbol{x}^*(\hat{\boldsymbol{a}})$ 不变，计算在真实环境下的运行成本。这里引入了 $\tilde{\boldsymbol{\xi}}$ 区别于 $\boldsymbol{\xi}$：

$$\mathcal{R}(\boldsymbol{x}^*, \boldsymbol{a}) = \min_{\tilde{\xi}} \quad \boldsymbol{c}^\top \tilde{\boldsymbol{\xi}} \tag{26}$$

$$\text{s.t.} \quad (\boldsymbol{x}^*, \tilde{\boldsymbol{\xi}}) \in \Omega \tag{27}$$

$$\boldsymbol{G}\tilde{\boldsymbol{\xi}} \le \boldsymbol{h} + \boldsymbol{M} \odot (\boldsymbol{1} - \boldsymbol{x}^*) \tag{28}$$

$$\boldsymbol{Q}\tilde{\boldsymbol{\xi}} \ge \boldsymbol{d}(\boldsymbol{a}) \tag{29}$$

对于约束(28) 中的 $\boldsymbol{M} \odot (\boldsymbol{1} - \boldsymbol{x}^*)$，当 $x^*_{ijk} = 1$ 时为 0，当 $x^*_{ijk} = 0$ 时为约束失效，因此退化为 LP。针对 Step 2 的问题，有如下的性质 1：

Proposition 1. *对于任意满足流守恒的路由方案 $\boldsymbol{x}$ 和任意非负的真实到达时间 $\boldsymbol{a}$，关于变量 $\tilde{\boldsymbol{\xi}}$ 的第二阶段补救线性规划总是可行的且目标函数有界。*

证明过程见 Appendix A.1。既然 Step 2 一定是可行的，我们的目标是最小化事后决策遗 Post-hoc Regret [Hu et al., 2023]，因此定义真实最优成本：

$$Z^*(\boldsymbol{a}) = \min_{\boldsymbol{x},\boldsymbol{\xi}} \Phi(\boldsymbol{\xi}) \tag{30}$$

随后，我们定义表示 Post-hoc Regret 的损失函数：

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{P}\sum_{p=1}^{P}\left[\mathcal{R}(\boldsymbol{x}^*(f(\boldsymbol{u}_p;\boldsymbol{\theta})), \boldsymbol{a}_p) - Z^*(\boldsymbol{a}_p)\right] \tag{31}$$

其中 $\boldsymbol{u}_p$ 表示第 p 个场景的所有特征输入。这里的每一组训练数据，也就是第 p 个场景，不能指单次航班，因为车辆 k 的路径 x^k_{ij} 是将多个航班串联在一起的，航班之间存在耦合，因此定义一个训练样本 p 代表一个完整的排班场景。$\boldsymbol{a}_p$ 记为第 p 个场景的所有航班真实到达时间，而 $Z^*(\boldsymbol{a}_p)$ 表示真实最优成本。在前向传播时，我们求解 MILP 得到离散的 $x^k_{ij} \in \{0,1\}$；而进行梯度回传时，$\boldsymbol{x}^*$ 是关于 $\hat{\boldsymbol{a}}$ 的不连续函数，其导数 $\frac{\partial \boldsymbol{x}^*}{\partial \hat{\boldsymbol{a}}}$ 在几乎所有点为 0，在跳变点不可导；而 $\mathcal{R}(\boldsymbol{x}, \boldsymbol{a})$ 是关于 $\boldsymbol{x}^*$ 的分段线性函数，其导数也不连续。因此，我们需要为 $\mathcal{L}(\boldsymbol{\theta})$ 寻找一个替代损失。

3.3 替代损失函数 $\mathcal{L}_{\text{surr}}$ 的设计

在 SPO 范式中，对于 Regret 的非凸和间断特性，是通过设计类似 Hinge 损失的 $\ell_{\text{SPO+}}$ 来通过对偶空间绕过原问题 [Elmachtoub and Grigas, 2022]；而出了 SPO 范式之外，还有通过黑盒微分的方法在目标函数里加随机噪声，计算目标函数的期望的梯度 [Berthet et al., 2020]。但是这两种方法都不适合我们的 $\mathcal{L}(\theta)$，因为我们已经提到 SPO+ 假设约束是固定的，而黑盒微分的方法采样效率低，且难以处理复杂的硬约束可行性。为此，我们采用了Mandi and Guns [2020] 所提出的基于内点法的替代技术，为 $\mathcal{L}(\theta)$ 构

造了一个如下所示的替代损失：

$$\mathcal{L}_{\text{surr}}(\boldsymbol{\theta};\mu) = \frac{1}{P}\sum_{p=1}^{P}\left[\tilde{\mathcal{R}}_{\mu}(\tilde{\boldsymbol{x}}_{\mu}^{*}(f(\boldsymbol{u}_p;\boldsymbol{\theta})),\boldsymbol{a}_p) - Z^{*}(\boldsymbol{a}_p)\right] + \frac{\gamma}{2}\|\boldsymbol{\theta}\|^2 \tag{32}$$

其中 $\mu > 0$ 为平滑参数，用于控制近似的逼近程度，当 $\mu \to 0$ 时，替代 $\mathcal{L}_{\text{surr}} \to \mathcal{L}$；$\gamma > 0$ 为正则化系数，用于防止预测模型过拟合。$\tilde{\boldsymbol{x}}_{\mu}^{*}(\cdot)$ 被称为名义平滑映射，意思是第一阶段 MILP 问题的连续化近似解，其不再是二元变量，而是位于 $[0,1]$ 区间内的连续值。它是通过下文所述的对数障碍法 (Log-barrier) 计算得出的，作为硬性承诺 [Hu et al., 2023] 但尚未经受真实运行后果检验的初始排班方案。$\tilde{\mathcal{R}}_{\mu}(\cdot,\cdot)$ 是在给定 $\tilde{\boldsymbol{x}}_{\mu}^{*}(\cdot)$ 时候在真实环境 $\boldsymbol{a}_p$ 中产生的成本。

在替代损失(32)中，最难的在于如何从神经网络的输出 $\hat{\boldsymbol{a}}$ 可导地映射到决策变量 $\tilde{\boldsymbol{x}}_{\mu}^{*}$。为此，我们引入了对数障碍法 (Log-barrier method)。这原本是凸优化领域中用于求解含不等式约束问题的一种内点法 [Frisch, 1955, Bertsekas, 1997]。其的基本思想是：不直接处理硬约束（如 $\boldsymbol{G\xi} \le \boldsymbol{h}$），而是将这些约束转化为目标函数中的惩罚项。Mandi and Guns [2020] 和 [Hu et al., 2023] 将其扩展到端到端的 DFL 中，以构建针对 MIP 的平滑近似。具体而言，对于形如 LHS ≤ RHS 的不等式约束，我们在目标函数中加入 $-\mu\log(\text{RHS}-\text{LHS})$ 项；当解位于可行域内部时，$\text{RHS}-\text{LHS} > 0$ 使该项为有限值，而当解逼近边界或不可行时，$\text{RHS}-\text{LHS} \to 0^{+}$ 从而该项 $\to +\infty$。在我们的问题中引入 log-barrier 项，既可以使得优化问题变成了一个强凸的光滑优化问题，也可以让这一惩罚项捕捉 $\hat{\boldsymbol{a}}$ 的变化对可行域几何形状的影响。

我们将 Step 1 的名义优化问题定义为如下的 log-barrier 平滑问题：

$$(\tilde{\boldsymbol{x}}_{\mu}^{*},\tilde{\boldsymbol{\xi}}_{\mu}^{*}) = \underset{\tilde{\boldsymbol{x}},\tilde{\boldsymbol{\xi}}}{\arg\min} \quad \Phi(\tilde{\boldsymbol{\xi}}) - \mu\cdot\sum_{m\in\mathcal{M}}\log\left(\mathcal{S}_m(\tilde{\boldsymbol{x}},\tilde{\boldsymbol{\xi}},\hat{\boldsymbol{a}})\right) \tag{33}$$

其中，$\mathcal{M}$ 代表所有不等式约束的索引集合，且对于 $\forall m \in \mathcal{M}$ 需要满足 $\mathcal{S}_m(\tilde{\boldsymbol{x}},\tilde{\boldsymbol{\xi}},\hat{\boldsymbol{a}}) > 0$。根据我们的约束形式 (**??**)-(**??**)，我们可以把 $\mathcal{S}$ 分成以下几类：

- 含有二元松弛变量的余量集合 $\mathcal{S}_1$：我们将其松弛为 $0 \le \tilde{x}_{ijk} \le 1$。这意味着每个变量 $\tilde{x}_{ijk}$ 有两个边界约束 $\tilde{x}_{ijk} \ge 0$ 和 $1-\tilde{x}_{ijk} \ge 0$。记 $\mathcal{S}_1 = [\tilde{\boldsymbol{x}}, \boldsymbol{1}-\tilde{\boldsymbol{x}}]^{\top}$
- 静态约束余量集合 $\mathcal{S}_2$：来自于原问题中的大 M 约束 $\boldsymbol{G\xi} \le \boldsymbol{h} + \boldsymbol{M}\odot(\boldsymbol{1}-\boldsymbol{x})$。我们定义 $\mathcal{S}_2 = \boldsymbol{h} + \boldsymbol{M}\odot(\boldsymbol{1}-\tilde{\boldsymbol{x}}) - \boldsymbol{G}\tilde{\boldsymbol{\xi}}$。
- 动态约束余量集合 $\mathcal{S}_3$：来源于原问题中含有 $\hat{a}_n$ 的约束 $\boldsymbol{Q\xi} \ge \boldsymbol{d}(\hat{\boldsymbol{a}})$。定义 $\mathcal{S}_3 = \boldsymbol{Q}\tilde{\boldsymbol{\xi}} - \boldsymbol{d}(\hat{\boldsymbol{a}})$。

在这三类集合中，$\mathcal{S}_1$ 是将离散问题转化为连续问题的关键，当平滑参数 $\mu \to 0$ 时，这一项会让 $\tilde{\boldsymbol{x}}$ 趋向于 0 或 1，从而使得连续解逼近整数解；对于 $\mathcal{S}_2$，可以直观理解为如果在 Step 2 中某个时间窗约束导致成本增加，这个梯度会通过 $\mathcal{S}_2$ 传导回 $\tilde{\boldsymbol{x}}$，从而让调度避开这些路径；而 $\mathcal{S}_3$ 则衡量了预测参数 $\hat{\boldsymbol{a}}$ 对可行域边界的扰动，在后续计算梯度的时候起到作用。上述三类集合满足 $\mathcal{S} = \mathcal{S}_1 \cup \mathcal{S}_2 \cup \mathcal{S}_3$。

基于上述松弛余量的分类，我们需要计算替代损失函数 $\mathcal{L}_{\text{surr}}$ 回传的梯度来更新 $\boldsymbol{\theta}$，可以由下式计算：

$$\nabla_{\boldsymbol{\theta}}\mathcal{L}_{\text{surr}} = \frac{1}{P}\sum_{p=1}^{P}\left[\nabla_{\hat{\boldsymbol{a}}}\mathcal{L}_{\text{surr}}(\hat{\boldsymbol{a}}_p)\cdot\frac{\partial\hat{\boldsymbol{a}}_p}{\partial\boldsymbol{\theta}}\right] + \gamma\boldsymbol{\theta} \tag{34}$$

其中 $\frac{\partial\hat{\boldsymbol{a}}}{\partial\boldsymbol{\theta}}$ 是神经网络的标准梯度回传过程，可以由 PyTorch 直接回传，而 $\nabla_{\hat{\boldsymbol{a}}}\mathcal{L}_{\text{surr}}$ 可以根据下面的 Proposition 2来进行计算 (证明过程见 Appendix A.2)。

Proposition 2. 对于平滑参数 $\mu > 0$，且 *Step 1* 的 *log-barrier* 问题的 *Hessian* 矩阵非奇异，替代损失函数 $\mathcal{L}_{surr}$ 关于预测值 $\hat{\boldsymbol{a}}$ 的梯度可以由下式算出：

$$\nabla_{\hat{\boldsymbol{a}}}\mathcal{L}_{surr} = \left[(\boldsymbol{M}\odot\lambda_{II}^{*}),\boldsymbol{0},\boldsymbol{0}\right]\cdot\begin{bmatrix}\boldsymbol{H} & \boldsymbol{E}^{\top}\\ \boldsymbol{E} & \boldsymbol{0}\end{bmatrix}^{-1}\cdot\begin{bmatrix}\boldsymbol{0}\\ \mu\boldsymbol{Q}^{\top}diag((\boldsymbol{S}_3^{*})^{-2})\nabla\boldsymbol{d}(\hat{\boldsymbol{a}})\\ \boldsymbol{0}\end{bmatrix} \tag{35}$$

其中 $\boldsymbol{\lambda}_{II}^{*}$ 为 *Step 2* 优化问题中 $\boldsymbol{h}+\boldsymbol{M}\odot(\boldsymbol{1}-\tilde{\boldsymbol{x}}_{\mu}^{*})$ 这一约束对应的最优对偶向量；$\boldsymbol{H}$ 表示 *Step 1* 的 *log-barrier* 问题中，*Lagrange* 函数 L 关于原始决策变量的 *Hessian* 矩阵，$\boldsymbol{E}$ 表示第一阶段问题中所有线性等式约束，满足 $\boldsymbol{E}\left[\tilde{\boldsymbol{x}},\tilde{\boldsymbol{\xi}}\right]^{\top}=\boldsymbol{e}$；$\boldsymbol{S}_3^{*}$ 指第一阶段最优解处，与预测参数相关的 $\mathcal{S}_3$，式中 $(\boldsymbol{S}_3^{*})^{-2}$ 表示对该向量的每个元素求平方倒数构成的向量；$\boldsymbol{Q}$ 指的是 *Step 1* 中含 $\hat{\boldsymbol{a}}$ 的约束关于变量 $\tilde{\boldsymbol{\xi}}$ 的系数矩阵；而 $\nabla\boldsymbol{d}(\hat{\boldsymbol{a}})$ 代表 $\boldsymbol{d}(\hat{\boldsymbol{a}})$ 关于预测值 $\hat{\boldsymbol{a}}$ 的 *Jacobi* 矩阵。

这一性质给出了替代损失的计算公式。公式 (35)再乘上 $\frac{\partial\hat{\boldsymbol{a}}}{\partial\boldsymbol{\theta}}$ 即是整个需要回传的梯度。通过这一替代损失，我们将在定义域内不可微分、非凸、间断的两步骤事后决策遗憾 $\mathcal{L}$ 转化为可以计算的 $\mathcal{L}_{\text{surr}}$。而针对这一替代损失，我们仍需要进行理论分析来说明 $\mathcal{L}$surr 是 $\mathcal{L}$ 的一个性质良好的替代。下面的 Theorem 1说明了对于 $\mathcal{L}_{\text{surr}}$ 而言，预测值 $\hat{\boldsymbol{a}}$ 到决策 $\tilde{\boldsymbol{x}}$ 的映射是光滑的。

Theorem 1. 对于一个固定的 $\mu > 0$，若 Ω 是一个非空的紧集且满足 *Slater* 条件，线性约束的系数矩阵 $\boldsymbol{E}$ 满秩，那么 *Step 1* 的 *log-barrier* 问题存在唯一的最优解 $(\tilde{\boldsymbol{x}}_{\mu}^{*},\tilde{\boldsymbol{\xi}}_{\mu}^{*},\boldsymbol{\nu}^{*})$，且映射 $\hat{\boldsymbol{a}}\mapsto(\tilde{\boldsymbol{x}}_{\mu}^{*}(\hat{\boldsymbol{a}}),\tilde{\boldsymbol{\xi}}_{\mu}^{*}(\hat{\boldsymbol{a}}),\boldsymbol{\nu}^{*}(\hat{\boldsymbol{a}}))$ 在预测参数空间内是连续可微的。进一步地，替代损失函数 $\mathcal{L}_{surr}(\boldsymbol{\theta};\mu)$ 关于模型参数 $\boldsymbol{\theta}$ 是连续可微的。

这一定理的证明可以见 Appendix A.3。若我们没有这一定理保障，而只是计算了梯度回传的公式，由于类似 SPO 损失函数的特性会导致梯度无法回传，从而无法训练模型 [Elmachtoub and Grigas, 2022]。而这一定理证明了 $\mathcal{L}_{\text{surr}}$ 涉及到的各个映射的平滑性，即它们都是至少是连续可微的，这就说明了我们上述 Proposition 2想要计算的梯度是存在且可以传回去的，这是利用梯度下降法来训练模型的基础。而进一步地，下面的 Theorem 2则说明了梯度不会爆炸这一性质。

Theorem 2. 若 Ω 是一个非空的紧集且满足 *Slater* 条件，线性约束的系数矩阵 $\boldsymbol{E}$ 满秩，$f(\boldsymbol{u};\boldsymbol{\theta})$ 的参数空间 $\boldsymbol{\Theta}$ 有界，且 $\|\nabla_{\boldsymbol{\theta}}f(\boldsymbol{u};\boldsymbol{\theta})\|_2$ 有界，那么 $\forall\mu>0$，$\exists C_{\mu}<+\infty$ 使得替代损失函数 $\mathcal{L}_{surr}(\boldsymbol{\theta};\mu)$ 关于参数 $\boldsymbol{\theta}$ 的梯度范数有如下上界：

$$\|\nabla_{\boldsymbol{\theta}}\mathcal{L}_{surr}(\boldsymbol{\theta};\mu)\|_2 \le C_{\mu} \tag{36}$$

Theorem 2的证明见 Appendix A.4。我们联合起来看上述 Theorem 1和 Theorem 2的意义。本质上，这两个定理为我们在端到端调度框架中使用基于梯度的优化算法（如 Adam 或 SGD）提供了数学保障。原始的 MIP 问题具有组合优化的离散本质，导致路由决策变量 $\boldsymbol{x}^{*}$ 关于预测值 $\hat{\boldsymbol{a}}$ 是阶跃函数）。如果在其上直接应用链式法则，梯度几乎处处为零，且在跳变点未定义，会带来梯度消失。而 Theorem 1证明了通过引入 log-barrier 项并构建多部映射，可以将决策空间构造为平滑的可微空间。这种平滑性使得决策遗憾可以回传来更新参数。而 Theorem 2证明了只要 $\mu>0$，最优解会出现在可行域内部，从而避免了 $\mathcal{S}\to 0$ 的可能性。这一有界性保证了参数 $\boldsymbol{\theta}$ 的更新是数值稳定的。

如果说上述两个定理说明的是 $\mathcal{L}_{\text{surr}}$ 自身可以满足可训练的性质，那么我们还需要说明其相较于 $\mathcal{L}$ 本身的可替代性。首先，对于给定的预测函数 f，我们定义经验风险 (Empirical risk) 为给定 P 个独立同

分布 (identically independent distribution, i.i.d.) 的样本的平均决策遗憾，其形式如下：

$$\hat{R}(f) = \frac{1}{P}\sum_{p=1}^{P} \ell(f(\boldsymbol{u}_p), \boldsymbol{a}_p) \tag{37}$$

其中 $\ell(\cdot,\cdot)$ 是损失函数。同样地，定义真实风险 (True risk) 如下:

$$R(f) = \mathbb{E}_{(\boldsymbol{u},\hat{\boldsymbol{a}})\sim\mathcal{D}}[\ell(f(\boldsymbol{u}_p), \boldsymbol{a}_p)] \tag{38}$$

其中 $(\boldsymbol{u}, \hat{\boldsymbol{a}})$ 服从于未知的联合分布 $\mathcal{D}$。如果说 $\hat{R}(f)$ 衡量了预测函数 f 在训练集上的表现，那么 $R(f)$ 则衡量了其在测试集上的性能。一般而言，损失函数在训练集上的表现要比在测试集上的表现好，我们定义两者之差 $(R(f) - \hat{R}(f))$ 为 f 的泛化误差。泛化误差衡量了预测函数从拟合的已知分布到未知分布之间的迁移能力 [Akbari et al., 2021]。对于泛化误差，一般用下面介绍的 Rademacher 复杂度来衡量其上界 [Mohri et al., 2018]。对于预测函数的假设类 $f \in \mathcal{H}$，其经验 Rademacher 复杂度定义为：

$$\hat{\mathfrak{R}}^P(\mathcal{H}) = \mathbb{E}_{\boldsymbol{\sigma}}\left[\sup_{f\in\mathcal{H}} \frac{1}{P}\sum_{p=1}^{P} \sigma_p \ell\left(f(\boldsymbol{u}_p;\boldsymbol{\theta}), \boldsymbol{a}_p\right)\right] \tag{39}$$

其中 $\boldsymbol{\sigma} = [\sigma_1, \ldots, \sigma_P]^\top$ 是 i.i.d. 的 Rademacher 变量，满足 $\mathbb{P}(\sigma_p = -1) = \mathbb{P}(\sigma_p = 1) = \frac{1}{2}$。类似地，定义给定数据集 $\mathbb{S} = \{(\boldsymbol{u}_p, \boldsymbol{a}_p)\}_{p=1}^P$ 上的期望 Rademacher 复杂度 $\mathfrak{R}^P(\mathcal{H}) = \mathbb{E}_{\mathbb{S}}[\hat{\mathfrak{R}}_P]$。已经有很多研究用 Rademacher 复杂度来衡量泛化误差的上界 [El Balghiti et al., 2023, Yang et al., 2025]，而回到我们的场景，我们首先想要说明的是，在训练集上已经能够最小化经验风险的 $\mathcal{L}_{\text{surr}}$，在面对未知分布的测试集上，其泛化性能可以得到保障。而下面的 Theorem 3说明了这一性质：

Theorem 3. *设 $\mathbb{S} = \{(\boldsymbol{u}_p, \boldsymbol{a}_p)\}_{p=1}^P$ 是从 $\mathcal{D}$ 中 i.i.d. 采样的数据。对于给定的 $\mu > 0$ 和假设函数类 $f \in \mathcal{H}$（其中 $f = f(;\boldsymbol{\theta}), \boldsymbol{\theta} \in \Theta$），$\forall\delta > 0$，至少有 $1-\delta$ 的概率，$\forall\boldsymbol{\theta} \in \Theta$，下面的泛化误差界成立：*

$$R_{surr}(f) \le \hat{R}_{surr}(f) + 2C_\mu \cdot \hat{\mathfrak{R}}^P(\mathcal{H}_{surr}) + 3\omega_\Xi(C)\sqrt{\frac{\log(2/\delta)}{2P}} \tag{40}$$

其中 $\omega_\Xi(C)$ 是对于所有 $\boldsymbol{\xi} \in \Xi, \boldsymbol{c} \in C$，替代损失函数 $\mathcal{L}_{surr}$ 的上界。

Theorem 3的证明见 Appendix A.5。这一定理保证了在给定训练集时，$\mathcal{L}_{\text{surr}}$ 的泛化误差的上界，定性地讲就是在训练集上若 $\mathcal{L}$ 表现的还可以，那在面对未知分布的测试集时，也不会表现地太差。而现在 $\mathcal{L}_{\text{surr}}$ 已经有了较好的理论保证，我们进一步讨论 $\mathcal{L}_{\text{surr}}$ 和 $\mathcal{L}$ 之间的关系，具体而言，若最小化 $\mathcal{L}_{\text{surr}}$ 的过程等价于最小化 $\mathcal{L}$ 的过程，即 $\mathcal{L}_{\text{surr}}$ 对于 $\mathcal{L}$ 来说是一致校准 (uniformly calibrated) 的，其超额风险有上界且可以趋于 0 [Liu and Grigas, 2021]，那 $\mathcal{L}_{\text{surr}}$ 才是一个好的替代损失。下面的 Corollary 1说明了这一点。

Corollary 1. *对于风险 $R(f) = \mathbb{E}_{(\boldsymbol{u},\boldsymbol{a})\sim\mathcal{D}}[\mathcal{L}(f(\boldsymbol{u};\boldsymbol{\theta}), \boldsymbol{a})]$，令 $f^* = \arg\min_{f\in\mathcal{H}} R(f)$ 为真实风险下的全局最优模型。令 $\hat{f}_{P,\mu} = \arg\min_{f\in\mathcal{H}} \hat{R}_{surr}(f;\mu)$ 为在包含 P 个样本的训练集上，通过最小化经验替代风险求得的替代模型。$\forall\delta > 0$，有至少 $1-\delta$ 的概率，通过替代损失训练得到的模型 $\hat{f}_{P,\mu}$ 所产生的真实超额风险满足：*

$$R(\hat{f}_{P,\mu}) - R(f^*) \le 4C_\mu \hat{\mathfrak{R}}^P(\mathcal{H}) + 6\omega_\Xi(C)\sqrt{\frac{\log(2/\delta)}{2P}} + 2\varphi(\mu) \tag{41}$$

其中 $\varphi(\mu) = \sup_{f\in\mathcal{H}} \sup_{\boldsymbol{u},\boldsymbol{a}} |\mathcal{L}(f(\boldsymbol{u};\boldsymbol{\theta}), \boldsymbol{a}) - \mathcal{L}_{surr}(f(\boldsymbol{u};\boldsymbol{\theta}), \boldsymbol{a};\mu)|$ 为平滑近似误差。当样本量 $P \to \infty$ 且平滑参数 $\mu \to 0^+$ 时，$R(\hat{f}_{P,\mu}) \to R(f^*)$。

Corollary 1的证明见 Appendix A.6。Theorem 3和 Corollary 1这一框架的理论收敛性与渐近最优性。决策遗憾 $\mathcal{L}$ 的阶跃性质导致其不具备 Lipschitz 连续性，因此难以直接约束经验风险与期望风险之间的泛化误差。而 Theorem 3表明，通过引入平滑参数 μ 所构造的替代损失函数 $\mathcal{L}_{\text{surr}}$ 具备 C_μ-Lipschitz 连续性。从而将复合损失函数族的 Rademacher 复杂度上界严格限制为 $\mathcal{H}$ 的复杂度。这在理论上保证了离散优化层的结构不会增加假设空间的统计复杂度。在此基础上，Corollary 1说明了 $\mathcal{L}_{\text{surr}}$ 相对于 $\mathcal{L}$ 的超额风险上界可以被分为由样本量 P 决定的统计泛化误差，以及由平滑参数 μ 决定的平滑近似误差。这说明当训练样本量 $P \to \infty$ 且平滑参数 $\mu \to 0^+$ 时，通过最小化连续可微的经验替代风险所求得的模型 $\hat{f}_{P,\mu}$，其真实期望风险 $R(\hat{f}_{P,\mu})$ 收敛于原问题下的全局最优风险 $R(f^*)$。这说明基于替代损失函数的梯度优化目标与原始飞行区 GSE 调度目标是渐近等价的。

4 Experiments

4.1 Toy example

A Proofs

A.1 Proposition 1的证明

证明. 要证明问题可行，等价于证明存在至少一个向量 $\tilde{\boldsymbol{\xi}}$ 满足 Step 2 的所有线性约束。由于 $\boldsymbol{x}$ 满足流守恒约束且网络 $\mathcal{G}$ 无环，$\boldsymbol{x}$ 确定的路径构成了一组由车辆 k 或 k' 执行的任务链：$\forall k \in \mathcal{K}$（或 $\forall k' \in \mathcal{K}'$），其路径上的节点序列为 $0 \to i_1 \to i_2 \cdots \to N+1$。

我们要构造一组足够大的 $\tilde{t}_i$，使其满足所有时间先后约束和 $\boldsymbol{a}$ 的限制。对于每个航班 $n \in \mathcal{F}$，其真实到达时间为 a_n。定义一个极大的基准时间：

$$T_{\text{base}} = \max_{n \in \mathcal{F}} a_n + \sum_{i \in \mathcal{N}} s_i + \sum_i \sum_j (\tau_{ij} + \tau'_{ij}) \tag{42}$$

对于路径上的任务节点，我们定义其拓扑排序：

$$\tilde{t}_i = T_{\text{base}} + \text{Order}(i) \cdot \Delta \tag{43}$$

其中 $\text{Order}(i)$ 是任务 i 在其车辆路径中的序号，$\Delta > 0$。由于 $\tilde{t}_i$ 极大，显然满足 $\tilde{t}_i \geq a_n$。

根据时间流转约束：

- 对于有人车：若 $x_{ij}^k = 1$，则定义 $\tilde{r}_{jk} = \tilde{t}_i + s_i + \tau_{ij}$。若 $x_{ij}^k = 0$，该约束中有大 M，$\tilde{r}_{jk}$ 可取任意非负值。
- 对于无人车：若 $x_{ijk'} = 1$，则定义 $\tilde{r}_{jk'} = \tilde{t}_i + s_i + \tau'_{ij}$。同理，若 $x'_{ijk'} = 0$，取 $\tilde{r}_{jk'} = 0$。

由于我们保证了 $\tilde{t}$ 的单调递增性，即 $\tilde{t}_j > \tilde{t}_i + s + \tau$，因此 $\tilde{t}_j \geq \tilde{r}_{jk}$ (或 $\tilde{r}_{jk'}$) 总是成立的。接下来我们构造一组可行的 $\tilde{\boldsymbol{w}}, \tilde{\boldsymbol{v}}, \tilde{\boldsymbol{y}}$。根据约束定义：

$$\tilde{w}_i = \max\left(0, \max_{k, j: x_{jik}=1} (\tilde{r}_{ik} - \tilde{t}_i), \max_{k', j: x_{jik'}=1} (\tilde{r}_{ik'} - \tilde{t}_i)\right) \tag{44}$$

这保证了约束 $t_i \geq r_i^k - w_i$ 恒成立。同样地，定义 $\tilde{v}_i = \max(0, \tilde{t}_i - a_n), \quad \forall i \in \mathcal{N}_n \cap (\mathcal{N}^{\text{arr}} \cup \mathcal{N}^{\text{fuel}}), \tilde{y}_n = \max(0, \tilde{t}_h + s_h - d_n^0), \quad \forall h \in \mathcal{N}_n \cap \mathcal{N}^{\text{push}}$。由于 $\tilde{\boldsymbol{t}}, \boldsymbol{a}$ 已定，$\tilde{\boldsymbol{v}}, \tilde{\boldsymbol{y}}$ 必存在。

综上所述，对于 Step 2 优化问题的可行域，总是非空的。且所有决策变量 $\tilde{y}, \tilde{w}, \tilde{v}$ 均非负。且所有成本系数 π, α, β 均为非负常数。因此，目标函数 $\Phi(\tilde{\boldsymbol{\xi}}) \geq 0$，存在下界。根据线性规划的基本定理 [Dantzig, 2002]，一个线性规划问题如果可行域非空且目标函数有下界，则其必定存在有限的最优解 $\Longrightarrow$ Step 2 的最优值 $\mathcal{R}(\boldsymbol{x}, \boldsymbol{a})$ 是有限的实数，证明完毕。

□

A.2 Proposition 2的证明

证明. 我们分两步来看这个计算过程，本质上 $\nabla_{\hat{\boldsymbol{a}}} \mathcal{L}_{\text{surr}}$ 可以根据链式法则写成下面的形式：

$$\nabla_{\hat{\boldsymbol{a}}} \mathcal{L}_{\text{surr}} = \frac{\partial \mathcal{L}_{\text{surr}}}{\partial \tilde{\mathcal{R}}_\mu} \frac{\partial \tilde{\mathcal{R}}_\mu}{\partial \tilde{\boldsymbol{x}}_\mu^*} \frac{\partial \tilde{\boldsymbol{x}}_\mu^*}{\partial \hat{\boldsymbol{a}}} \tag{45}$$

根据 (32)中 $\mathcal{L}_{\text{surr}}$ 的定义，$\frac{\partial \mathcal{L}_{\text{surr}}}{\partial \tilde{\mathcal{R}}_\mu} = 1$。而第二项 $\frac{\partial \tilde{\mathcal{R}}_\mu}{\partial \tilde{\boldsymbol{x}}_\mu^*}$ 是 Step 2 的成本对于车辆调度决策的偏导数，这反映了当第一阶段给出的 $\tilde{\boldsymbol{x}}_\mu^*$ 发生微小变化时，第二阶段的真实成本如何变化。根据约束 (28)，$\tilde{\boldsymbol{x}}_\mu^*$ 仅出现在 RHS，其关于 $\tilde{\boldsymbol{x}}_\mu^*$ 的 Jacobi 矩阵为：

$$\frac{\partial}{\partial \tilde{\boldsymbol{x}}_\mu^*} \left[\boldsymbol{h} + \boldsymbol{M} \odot (\mathbf{1} - \tilde{\boldsymbol{x}}_\mu^*) \right] = -\text{diag}(\boldsymbol{M}) \tag{46}$$

设 $\boldsymbol{\lambda}_{\text{II}}^*$ 为这一约束对应的最优对偶变量向量。应用链式法则：

$$\begin{aligned} \frac{\partial \tilde{\mathcal{R}}_\mu}{\partial \tilde{\boldsymbol{x}}_\mu^*} &= \frac{\partial \tilde{\mathcal{R}}_\mu}{\partial \left[\boldsymbol{h} + \boldsymbol{M} \odot (\mathbf{1} - \tilde{\boldsymbol{x}}_\mu^*) \right]} \cdot \frac{\partial \left[\boldsymbol{h} + \boldsymbol{M} \odot (\mathbf{1} - \tilde{\boldsymbol{x}}_\mu^*) \right]}{\partial \tilde{\boldsymbol{x}}_\mu^*} \\ &= (-\boldsymbol{\lambda}_{\text{II}}^*)^\top \cdot (-\text{diag}(\boldsymbol{M})) \\ &= (\boldsymbol{M} \odot \boldsymbol{\lambda}_{\text{II}}^*)^\top \end{aligned} \tag{47}$$

对于第三项 $\frac{\partial \tilde{\boldsymbol{x}}_\mu^*}{\partial \hat{\boldsymbol{a}}}$，由于 $\tilde{\boldsymbol{x}}_\mu^*$ 是第一阶段 log-barrier 问题的最优解，因此满足 KKT 一阶平稳性条件。首先，我们需要显式地写出第一阶段平滑问题的 Lagrange 函数。记 $\boldsymbol{E}$ 和 $\boldsymbol{e}$ 分别为所有线性等式约束的系数矩阵和右端项向量，$\boldsymbol{\nu}^*$ 为对应的对偶变量向量，Step 1 的 Lagrange 函数由下式给出：

$$L(\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{\xi}}, \boldsymbol{\nu}; \hat{\boldsymbol{a}}) = \Phi(\tilde{\boldsymbol{\xi}}) - \mu \cdot \sum_{m \in \mathcal{M}} \log(\mathcal{S}_m(\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{\xi}}, \hat{\boldsymbol{a}})) + \boldsymbol{\nu}^\top \left(\boldsymbol{E} \left[\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{\xi}} \right]^\top - \boldsymbol{e} \right) \tag{48}$$

Step 1 的最优解必须满足 KKT 条件，因此：

$$\begin{cases} \nabla_{\tilde{\boldsymbol{x}}_\mu^*} L(\tilde{\boldsymbol{x}}_\mu^*, \tilde{\boldsymbol{\xi}}_\mu^*, \boldsymbol{\nu}^*; \hat{\boldsymbol{a}}) = \mathbf{0} \\ \nabla_{\tilde{\boldsymbol{\xi}}_\mu^*} L(\tilde{\boldsymbol{x}}_\mu^*, \tilde{\boldsymbol{\xi}}_\mu^*, \boldsymbol{\nu}^*; \hat{\boldsymbol{a}}) = \mathbf{0} \\ \boldsymbol{E} \left[\tilde{\boldsymbol{x}}_\mu^*, \tilde{\boldsymbol{\xi}}_\mu^* \right]^\top - \boldsymbol{e} = \mathbf{0} \end{cases} \tag{49}$$

两端对 $\hat{\boldsymbol{a}}$ 求全微分，展开后的全微分方程组矩阵形式如下：

$$\begin{bmatrix} \nabla^2_{\tilde{\boldsymbol{x}}_\mu^* \tilde{\boldsymbol{x}}_\mu^*} L & \nabla^2_{\tilde{\boldsymbol{x}}_\mu^* \tilde{\boldsymbol{\xi}}_\mu^*} L & \nabla^2_{\tilde{\boldsymbol{x}}_\mu^* \boldsymbol{\nu}} L \\ \nabla^2_{\tilde{\boldsymbol{\xi}}_\mu^* \tilde{\boldsymbol{x}}_\mu^*} L & \nabla^2_{\tilde{\boldsymbol{\xi}}_\mu^* \tilde{\boldsymbol{\xi}}_\mu^*} L & \nabla^2_{\tilde{\boldsymbol{\xi}}_\mu^* \boldsymbol{\nu}} L \\ \nabla^2_{\boldsymbol{\nu} \tilde{\boldsymbol{x}}_\mu^*} L & \nabla^2_{\boldsymbol{\nu} \tilde{\boldsymbol{\xi}}_\mu^*} L & \nabla^2_{\boldsymbol{\nu}\boldsymbol{\nu}} L \end{bmatrix} \cdot \begin{bmatrix} \mathrm{d}\tilde{\boldsymbol{x}}_\mu^* \\ \mathrm{d}\tilde{\boldsymbol{\xi}}_\mu^* \\ \mathrm{d}\boldsymbol{\nu}^* \end{bmatrix} + \begin{bmatrix} \nabla^2_{\tilde{\boldsymbol{x}}_\mu^* \hat{\boldsymbol{a}}} L \\ \nabla^2_{\tilde{\boldsymbol{\xi}}_\mu^* \hat{\boldsymbol{a}}} L \\ \nabla^2_{\boldsymbol{\nu} \hat{\boldsymbol{a}}} L \end{bmatrix} \cdot \mathrm{d}\hat{\boldsymbol{a}} = \mathbf{0} \tag{50}$$

其中左上角的 2×2 分块即为 Lagrange 函数关于原始决策变量的 Hessian 矩阵 $\boldsymbol{H}$：

$$\boldsymbol{H} = \begin{bmatrix} \nabla^2_{\tilde{\boldsymbol{x}}^*_\mu \tilde{\boldsymbol{x}}^*_\mu} L & \nabla^2_{\tilde{\boldsymbol{x}}^*_\mu \tilde{\boldsymbol{\xi}}^*_\mu} L \\ \nabla^2_{\tilde{\boldsymbol{\xi}}^*_\mu \tilde{\boldsymbol{x}}^*_\mu} L & \nabla^2_{\tilde{\boldsymbol{\xi}}^*_\mu \tilde{\boldsymbol{\xi}}^*_\mu} L \end{bmatrix} \tag{51}$$

其中与对偶变量 $\boldsymbol{\nu}$ 相关的偏导数对应于等式约束的系数矩阵 $\boldsymbol{E}$。我们将 $\boldsymbol{E}$ 拆分为对应 $\tilde{\boldsymbol{x}}^*_\mu$ 的列 $\boldsymbol{E}_{\tilde{\boldsymbol{x}}^*_\mu}$ 和对应 $\tilde{\boldsymbol{\xi}}$ 的列 $\boldsymbol{E}_{\tilde{\boldsymbol{\xi}}^*_\mu}$，即 $\boldsymbol{E} = [\boldsymbol{E}_{\tilde{\boldsymbol{x}}^*_\mu}, \boldsymbol{E}_{\tilde{\boldsymbol{\xi}}^*_\mu}]$，因此有：

$$\begin{aligned} \nabla^2_{\tilde{\boldsymbol{x}}^*_\mu \boldsymbol{\nu}} L &= \boldsymbol{E}^\top_{\tilde{\boldsymbol{x}}^*_\mu} \\ \nabla^2_{\tilde{\boldsymbol{\xi}}^*_\mu \boldsymbol{\nu}} L &= \boldsymbol{E}^\top_{\tilde{\boldsymbol{\xi}}^*_\mu} \\ \nabla^2_{\boldsymbol{\nu}\boldsymbol{\nu}} L &= \boldsymbol{0} \end{aligned} \tag{52}$$

接下来，我们需要计算 Lagrange 函数梯度关于 $\hat{\boldsymbol{a}}$ 的偏导数。对于 $\boldsymbol{\nu}$ 分量，等式约束 $\boldsymbol{E}\left[\tilde{\boldsymbol{x}}^*_\mu, \tilde{\boldsymbol{\xi}}^*_\mu\right]^\top - \boldsymbol{e}$ 中不含 $\hat{\boldsymbol{a}}$，因此 $\nabla^2_{\boldsymbol{\nu}\hat{\boldsymbol{a}}} L = \boldsymbol{0}$。而对于 $\tilde{\boldsymbol{x}}^*_\mu$ 分量，L 中包含 $\hat{\boldsymbol{a}}$ 的项仅存在于对数障碍项 $-\mu \sum_{m\in\mathcal{M}} \log(\mathcal{S}_m)$ 中，且只有第三类松弛余量 $\mathcal{S}_3$，即预测相关约束 $\boldsymbol{Q}\tilde{\boldsymbol{\xi}} \geq \boldsymbol{d}(\hat{\boldsymbol{a}})$ 包含 $\hat{\boldsymbol{a}}$，则 $\mathcal{S}_m = [\boldsymbol{Q}\tilde{\boldsymbol{\xi}} - \boldsymbol{d}(\hat{\boldsymbol{a}})]_m$。而这些 $\mathcal{S}_m$ 并不包含 $\tilde{\boldsymbol{x}}$，因此 $\nabla^2_{\tilde{\boldsymbol{x}}\hat{\boldsymbol{a}}} L = \boldsymbol{0}$。

对于 $\tilde{\boldsymbol{\xi}}$ 分量，考察 $\nabla_{\tilde{\boldsymbol{\xi}}} L$ 中涉及 $\hat{\boldsymbol{a}}$ 的部分：

$$\nabla_{\tilde{\boldsymbol{\xi}}}(-\mu \sum_{m\in\mathcal{M}} \log \mathcal{S}_m) = -\mu \sum_{m\in\mathcal{M}} \frac{1}{\mathcal{S}_m} \nabla_{\tilde{\boldsymbol{\xi}}} \mathcal{S}_m \tag{53}$$

其中对于预测约束，有 $\nabla_{\tilde{\boldsymbol{\xi}}} \mathcal{S}_m = \boldsymbol{Q}^\top_{m\cdot}$。记 $\nabla \boldsymbol{d}_m$ 是 Jacobi 矩阵的第 m 行，上式关于 $\hat{\boldsymbol{a}}$ 求导得：

$$\begin{aligned} \frac{\partial}{\partial \hat{\boldsymbol{a}}} \left(-\mu \sum_{m\in\mathcal{M}} \frac{1}{\mathcal{S}_m} \boldsymbol{Q}^\top_{m\cdot} \right) &= -\mu \sum_{m\in\mathcal{M}} \boldsymbol{Q}^\top_{m\cdot} \left(-\frac{1}{\mathcal{S}_m^2} \right) \frac{\partial \mathcal{S}_m}{\partial \hat{\boldsymbol{a}}} \\ &= \mu \sum_{m\in\mathcal{M}} \boldsymbol{Q}^\top_{m\cdot} \frac{1}{\mathcal{S}_m^2} (-\nabla \boldsymbol{d}_m(\hat{\boldsymbol{a}})) \\ &= -\mu \boldsymbol{Q}^\top \mathrm{diag}(\boldsymbol{\mathcal{S}}_3^{-2}) \nabla \boldsymbol{d}(\hat{\boldsymbol{a}}) \end{aligned} \tag{54}$$

其中 $\boldsymbol{\mathcal{S}}^*_3 = \boldsymbol{Q}\tilde{\boldsymbol{\tau}}^*_\mu - \boldsymbol{d}(\hat{\boldsymbol{a}})$ 指第一阶段最优解处，与预测参数相关的第三类松弛余量向量。将计算出的块矩阵代回全微分方程，并移项，得到：

$$\begin{bmatrix} \boldsymbol{H} & \boldsymbol{E}^\top \\ \boldsymbol{E} & \boldsymbol{0} \end{bmatrix} \cdot \begin{bmatrix} \mathrm{d}\tilde{\boldsymbol{x}}^*_\mu \\ \mathrm{d}\tilde{\boldsymbol{\xi}}^*_\mu \\ \mathrm{d}\boldsymbol{\nu}^* \end{bmatrix} + \begin{bmatrix} \boldsymbol{0} \\ -\mu \boldsymbol{Q}^\top \mathrm{diag}((\boldsymbol{\mathcal{S}}^*_3)^{-2}) \nabla \boldsymbol{d}(\hat{\boldsymbol{a}}) \\ \boldsymbol{0} \end{bmatrix} \cdot \mathrm{d}\hat{\boldsymbol{a}} = \boldsymbol{0} \tag{55}$$

两边左乘分块矩阵的逆矩阵，整理得到：

$$\begin{bmatrix} \frac{\partial \tilde{\boldsymbol{x}}^*_\mu}{\partial \hat{\boldsymbol{a}}} \\ \frac{\partial \tilde{\boldsymbol{\xi}}^*_\mu}{\partial \hat{\boldsymbol{a}}} \\ \frac{\partial \boldsymbol{\nu}^*}{\partial \hat{\boldsymbol{a}}} \end{bmatrix} = \begin{bmatrix} \boldsymbol{H} & \boldsymbol{E}^\top \\ \boldsymbol{E} & \boldsymbol{0} \end{bmatrix}^{-1} \begin{bmatrix} \boldsymbol{0} \\ \mu \boldsymbol{Q}^\top \mathrm{diag}((\boldsymbol{\mathcal{S}}^*_3)^{-2}) \nabla \boldsymbol{d}(\hat{\boldsymbol{a}}) \\ \boldsymbol{0} \end{bmatrix} \tag{56}$$

令 KKT 矩阵为 $\boldsymbol{K}$，交叉导数向量为 $\boldsymbol{V}$，即

$$\boldsymbol{K} = \begin{bmatrix} \boldsymbol{H} & \boldsymbol{E}^\top \\ \boldsymbol{E} & \boldsymbol{0} \end{bmatrix}, \quad \boldsymbol{V} = \begin{bmatrix} \boldsymbol{0} \\ \mu \boldsymbol{Q}^\top \mathrm{diag}((\boldsymbol{\mathcal{S}}^*_3)^{-2}) \nabla \boldsymbol{d}(\hat{\boldsymbol{a}}) \\ \boldsymbol{0} \end{bmatrix} \tag{57}$$

根据隐函数定理推导结果：

$$\begin{bmatrix} \frac{\partial \tilde{\boldsymbol{x}}_\mu^*}{\partial \hat{\boldsymbol{a}}} \\ \frac{\partial \tilde{\boldsymbol{\xi}}_\mu^*}{\partial \hat{\boldsymbol{a}}} \\ \frac{\partial \boldsymbol{\nu}^*}{\partial \hat{\boldsymbol{a}}} \end{bmatrix} = \boldsymbol{K}^{-1}\boldsymbol{V} \tag{58}$$

为了进行对应，我们将第二阶段的梯度写为行向量形式，由于第二阶段对偶变量 $\boldsymbol{\lambda}_{\mathrm{II}}^*$ 仅对应于 $\tilde{\boldsymbol{x}}_\mu^*$ 的维度，对于 $\tilde{\boldsymbol{\xi}}_\mu^*$ 和 $\boldsymbol{\nu}^*$ 的影子价格都是 $\mathbf{0}$，因此定义：

$$\boldsymbol{\Lambda}_{\mathrm{II}} = \left[(\boldsymbol{M} \odot \boldsymbol{\lambda}_{\mathrm{II}}^*), \mathbf{0}, \mathbf{0}\right] \tag{59}$$

最终根据链式法则，$\mathcal{L}_{\mathrm{surr}}$ 的梯度计算公式如下：

$$\begin{aligned} \nabla_{\hat{\boldsymbol{a}}} \mathcal{L}_{\mathrm{surr}} &= \frac{\partial \mathcal{L}_{\mathrm{surr}}}{\partial \tilde{\mathcal{R}}_\mu} \frac{\partial \tilde{\mathcal{R}}_\mu}{\partial \tilde{\boldsymbol{x}}_\mu^*} \frac{\partial \tilde{\boldsymbol{x}}_\mu^*}{\partial \hat{\boldsymbol{a}}} \\ &= \boldsymbol{\Lambda}_{\mathrm{II}} \cdot \left(\boldsymbol{K}^{-1}\boldsymbol{V}\right)_1 \\ &= \left[(\boldsymbol{M} \odot \boldsymbol{\lambda}_{\mathrm{II}}^*), \mathbf{0}, \mathbf{0}\right] \cdot \begin{bmatrix} \boldsymbol{H} & \boldsymbol{E}^\top \\ \boldsymbol{E} & \mathbf{0} \end{bmatrix}^{-1} \cdot \left[\mathbf{0}, \mu \boldsymbol{Q}^\top \mathrm{diag}((\boldsymbol{\mathcal{S}}_3^*)^{-2}) \nabla \boldsymbol{d}(\hat{\boldsymbol{a}}), \mathbf{0}\right]^\top \end{aligned} \tag{60}$$

这样，我们就推导出了梯度回传更新预测模型参数 $\boldsymbol{\theta}$ 的公式。 □

A.3 Theorem 1的证明

证明. 我们来构建描述最优解条件的 KKT 系统，并证明其的 Jacobi 矩阵是可逆的。第一阶段平滑问题的拉格朗日函数 L 定义为：

$$L(\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{\xi}}, \boldsymbol{\nu}; \hat{\boldsymbol{a}}) = \Phi(\tilde{\boldsymbol{\xi}}) - \mu \sum_{m \in \mathcal{M}} \log(\mathcal{S}_m(\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{\xi}}, \hat{\boldsymbol{a}})) + \boldsymbol{\nu}^\top \left(\boldsymbol{E}\left[\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{\xi}}\right]^\top - \boldsymbol{e}\right)$$

这就是 (48)的形式。根据一阶最优性条件 [Boyd and Vandenberghe, 2004]，最优解 $(\tilde{\boldsymbol{x}}_\mu^*, \tilde{\boldsymbol{\xi}}_\mu^*, \boldsymbol{\nu}^*)$ 是以下非线性方程组的根:

$$\boldsymbol{\Psi}(\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{\xi}}, \boldsymbol{\nu}; \hat{\boldsymbol{a}}) = \begin{bmatrix} \nabla_{\tilde{\boldsymbol{x}}} L(\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{\xi}}, \boldsymbol{\nu}; \hat{\boldsymbol{a}}) \\ \nabla_{\tilde{\boldsymbol{\xi}}} L(\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{\xi}}, \boldsymbol{\nu}; \hat{\boldsymbol{a}}) \\ \boldsymbol{E}\left[\tilde{\boldsymbol{x}},\ \tilde{\boldsymbol{\xi}}\right]^\top - \boldsymbol{e} \end{bmatrix} = \mathbf{0} \tag{61}$$

接下来我们考察 $\boldsymbol{\Psi}$ 关于所有变量的可微性。首先，目标函数 $\Phi(\tilde{\boldsymbol{\xi}})$ 是线性的，显然可微；其次，$-\mu \log(\mathcal{S}_m)$ 在可行域内（$\mathcal{S}_m > 0$ 是可微的；松弛项是线性约束的集合，也显然是可微的。因此 $\boldsymbol{\Psi}$ 是可微的、光滑的。

接下来，我们计算 $\boldsymbol{\Psi}$ 关于变量 $(\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{\xi}}, \boldsymbol{\nu})$ 的 Jacobi 矩阵，即我们在 Proposition 2中定义的 $\boldsymbol{K}$：

$$\nabla_{(\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{\xi}}, \boldsymbol{\nu})} \boldsymbol{\Psi} = \begin{bmatrix} \nabla^2_{\tilde{\boldsymbol{x}}\tilde{\boldsymbol{x}}} L & \nabla^2_{\tilde{\boldsymbol{x}}\tilde{\boldsymbol{\xi}}} L & \boldsymbol{E}_{\tilde{\boldsymbol{x}}}^\top \\ \nabla^2_{\tilde{\boldsymbol{\xi}}\tilde{\boldsymbol{x}}} L & \nabla^2_{\tilde{\boldsymbol{\xi}}\tilde{\boldsymbol{\xi}}} L & \boldsymbol{E}_{\tilde{\boldsymbol{\xi}}}^\top \\ \boldsymbol{E}_{\tilde{\boldsymbol{x}}} & \boldsymbol{E}_{\tilde{\boldsymbol{\xi}}} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \boldsymbol{H} & \boldsymbol{E}^\top \\ \boldsymbol{E} & \mathbf{0} \end{bmatrix} \tag{62}$$

其中 $\boldsymbol{H}$ 来源于对数障碍项的二阶导数：

$$\boldsymbol{H} = \mu \sum_{m \in \mathcal{M}} \frac{1}{\mathcal{S}_m^2} (\nabla \mathcal{S}_m)(\nabla \mathcal{S}_m)^\top \tag{63}$$

由于函数 $-\log(\cdot)$ 是凸函数，且 $\mu > 0$，在 Slater 条件满足（即 $\mathcal{S}_m > 0$）的前提下，$\boldsymbol{H}$ 是正定矩阵，即 $\boldsymbol{H} \succ 0$，且根据我们的假设，$\boldsymbol{E}$ 是满秩的 $\Longrightarrow \begin{bmatrix} \boldsymbol{H} & \boldsymbol{E}^\top \\ \boldsymbol{E} & \boldsymbol{0} \end{bmatrix}$ 是非奇异的。因此，$\boldsymbol{K}$ 可逆。那么存在唯一的连续可微映射 [Cukier et al., 1978]，记为 $\hat{\boldsymbol{a}} \mapsto (\tilde{\boldsymbol{x}}_\mu^*, \tilde{\boldsymbol{\xi}}_\mu^*, \boldsymbol{\nu}^*)$，使得其导数可以通过下式计算：

$$\begin{bmatrix} \frac{\partial \tilde{\boldsymbol{x}}_\mu^*}{\partial \hat{\boldsymbol{a}}} & \frac{\partial \tilde{\boldsymbol{\xi}}_\mu^*}{\partial \hat{\boldsymbol{a}}} & \frac{\partial \boldsymbol{\nu}^*}{\partial \hat{\boldsymbol{a}}} \end{bmatrix} = -\boldsymbol{K}^{-1} \cdot \nabla^2_{(\tilde{\boldsymbol{x}}, \tilde{\boldsymbol{\xi}}, \boldsymbol{\nu}) \hat{\boldsymbol{a}}} \Psi \tag{64}$$

由于 $\boldsymbol{K}^{-1}$ 和右侧的交叉导数项均为连续函数，因此 $\tilde{\boldsymbol{x}}_\mu^*(\hat{\boldsymbol{a}}), \tilde{\boldsymbol{\xi}}_\mu^*(\hat{\boldsymbol{a}}), \boldsymbol{\nu}^*(\hat{\boldsymbol{a}})$ 关于 $\hat{\boldsymbol{a}}$ 都是连续可微的。

接下来，为了说明 $\mathcal{L}_{\text{surr}}$ 关于参数 $\boldsymbol{\theta}$ 的可微性，我们要从其构成来看，本质上 $\mathcal{L}_{\text{surr}}$ 是如下映射的复合：

$$\boldsymbol{\theta} \mapsto \mathcal{L}_{\text{surr}} = \{(\tilde{\boldsymbol{x}}_\mu^*, \hat{\boldsymbol{a}}, \boldsymbol{a}\}) \mapsto \mathcal{R}_\mu^*\} \circ \{\hat{\boldsymbol{a}} \mapsto (\tilde{\boldsymbol{x}}_\mu^*, \tilde{\boldsymbol{\xi}}_\mu^*, \boldsymbol{\nu}^*)\} \circ \{\boldsymbol{u} \mapsto \hat{\boldsymbol{a}}\} \tag{65}$$

其中关于预测映射 $\boldsymbol{u} \mapsto \hat{\boldsymbol{a}}$，使用光滑的激活函数（如 Sigmoid, Tanh, Softmax 等）关于参数 $\boldsymbol{\theta}$ 是 C^∞ 光滑的；关于 $\hat{\boldsymbol{a}} \mapsto (\tilde{\boldsymbol{x}}_\mu^*, \tilde{\boldsymbol{\xi}}_\mu^*, \boldsymbol{\nu}^*)$，由于 $\boldsymbol{K}$ 在 $\mu > 0$ 时非奇异，因此该映射也是连续可微的；关于其导数，由于 $\mathcal{S}^{-2}$ 在内点处有界，该导数是局部 Lipschitz 连续的。最后一项 $\tilde{\boldsymbol{x}}_\mu^*, \hat{\boldsymbol{a}}, \boldsymbol{a}\}) \mapsto \mathcal{R}_\mu^*$，由于最优值函数关于其 RHS 是凸的且分段线性的 [Gal, 2010]，因此这一映射是 Lipschitz 连续的。在非退化点最优对偶解 $\boldsymbol{\lambda}_{\text{II}}^*$ 唯一；在退化点也是次可微的，可以求其次梯度。

综上所述，根据链式法则，$\mathcal{L}_{\text{surr}}$ 关于参数 $\boldsymbol{\theta}$ 是连续且可微的。

□

A.4 Theorem 2的证明

证明. 包含正则化项的替代损失函数的梯度为：

$$\nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{surr}} = (\nabla_{\hat{\boldsymbol{a}}} \mathcal{L}_{\text{surr}}) \cdot \nabla_{\boldsymbol{\theta}} f(\boldsymbol{u}; \boldsymbol{\theta}) + \gamma \boldsymbol{\theta} \tag{66}$$

式中，由于 $\|\nabla_{\boldsymbol{\theta}} f(\boldsymbol{u}; \boldsymbol{\theta})\|_2$ 和正则化项 $\|\gamma \boldsymbol{\theta}\|_2$ 均有界，我们只需证明单样本的预测值梯度 $\|\nabla_{\hat{\boldsymbol{a}}} \mathcal{L}_{\text{surr}}\|_2$ 有界即可。

回顾在 Proposition 2中的梯度公式 (35)，我们分成三部分来看：

- 第一部分 $\left[(\boldsymbol{M} \odot \boldsymbol{\lambda}_{\text{II}}^*), \boldsymbol{0}, \boldsymbol{0}\right]$：非零部分为 $\boldsymbol{M} \odot \boldsymbol{\lambda}_{\text{rec}}^*$。而 $\boldsymbol{\lambda}_{\text{rec}}^*$ 为 Step 2 的 LP 的最优对偶变量。根据 Proposition 1，该 LP 恒有界，那么其对偶问题也有界且有有限的最优解。因此 $\exists C_A < +\infty$ 使得 $\|\boldsymbol{\lambda}_{\text{rec}}^*\|_2 \le C_1$，因此这一项的范数有界。
- 第二部分 $\begin{bmatrix} \boldsymbol{H} & \boldsymbol{E}^\top \\ \boldsymbol{E} & \boldsymbol{0} \end{bmatrix}^{-1}$：这是 KKT 矩阵的逆。根据 Theorem 1，在最优解处 $\boldsymbol{H} \succ 0$ 且 $\boldsymbol{E}$ 满秩，因此 KKT 矩阵是非奇异的。由于可行域是紧的，最优解 $(\tilde{\boldsymbol{x}}_\mu^*, \tilde{\boldsymbol{\xi}}_\mu^*, \boldsymbol{\nu}^*)$ 也必然落在一个紧集内。而连续映射在紧集上的像仍然是有界的紧集 [Dudley, 2018]。因此，$\exists C_B < +\infty$ 使得 KKT 矩阵的谱范数 $\|\boldsymbol{K}^{-1}\|_2 \le C_2$。

- 第三部分 $\left[\mathbf{0}, \mu \boldsymbol{Q}^\top \mathrm{diag}((\mathcal{S}_3^*)^{-2}) \nabla \boldsymbol{d}(\hat{\boldsymbol{a}}), \mathbf{0}\right]^\top$：由于 $\mu < +\infty$，而 $\boldsymbol{Q}, \nabla \boldsymbol{d}(\hat{\boldsymbol{a}})$ 都有界，因此关键在于说明对角矩阵的元素 $(\mathcal{S}_{3,m}^*)^{-2}$ 有界，证明如下。

对于第三部分，我们假设存在某个约束 m，使得当平滑参数固定为 $\mu > 0$ 时，其松弛余量 $\mathcal{S}_{3,m}^* \to 0$。根据 Step 1 的目标函数定义，当 $\mathcal{S}_{3,m}^* \to 0$ 时，$-\mu \log(\mathcal{S}_{3,m}^*) \to +\infty$。然而，由于满足 Slater 条件，可行域内必然存在一个严格内点，使在该内点处的目标函数值为有限常数，这与求极小值问题的最优解不可能使目标函数趋于无穷大相矛盾。因此，对于给定的 $\mu > 0$，存在一个与 μ 相关的下界 $\delta_\mu > 0$，使得最优解处必有 $\mathcal{S}_3^* \geq \delta_\mu \mathbf{1}$。因此，$(\mathcal{S}_{3,m}^*)^{-2} \leq \frac{1}{\delta_\mu^2} < +\infty$。即 $\exists C_3 < +\infty$ 使得 $\|\mu \boldsymbol{Q}^\top \mathrm{diag}((\mathcal{S}_3^*)^{-2}) \nabla \boldsymbol{d}(\hat{\boldsymbol{a}})\|_2 \leq C_3$。

综上，三部分的梯度范数都有界，那么就可以保证：

$$\|\nabla_{\boldsymbol{\theta}} \mathcal{L}\|_2 \leq C_\mu = C_1 \cdot C_2 \cdot C_3 \tag{67}$$

□

A.5 Theorem 3的证明

证明. 记如下 $\Gamma(\mathbb{S})$ 为给定样本集合 $\mathbb{S}$ 下，衡量真实风险和期望风险的最大偏差上界的量：

$$\Gamma(\mathbb{S}) = \sup_{f \in \mathcal{H}} \left[R_{\mathrm{surr}}(f) - \hat{R}_{\mathrm{surr}}(f)\right] \tag{68}$$

我们更改训练集 $\mathbb{S}$ 中的任意一个样本 $(\boldsymbol{u}_p, \boldsymbol{a}_p)$ 为 $(\boldsymbol{u}'_p, \boldsymbol{a}'_p)$，得到新的训练集 $\mathbb{S}'$。对于形式为 $\min_{\boldsymbol{\xi} \in \Xi} \boldsymbol{c}^\top \boldsymbol{\xi}$ 的优化问题，我们记 $\omega_\Xi(\boldsymbol{c}) = \max_{\boldsymbol{\xi} \in \Xi}\{\boldsymbol{c}^\top \boldsymbol{\xi}\} - \min_{\boldsymbol{\xi} \in \Xi}\{\boldsymbol{c}^\top \boldsymbol{\xi}\}$，令 $\omega_\Xi(C) = \sup_{\boldsymbol{c} \in C} \omega_\Xi(\boldsymbol{c})$，这是 $\mathcal{L}_{\mathrm{surr}}$ 的上界。

由于 $\mathcal{L}_{\mathrm{surr}}$ 的取值范围在 $[0, \omega_\Xi(C)]$，经验风险 $\hat{R}_{\mathrm{surr}}$ 的变化量最多为 $\frac{\omega_\Xi(C)}{P}$。即：

$$|\Gamma(\mathbb{S}) - \Gamma(\mathbb{S}')| \leq \frac{\omega_\Xi(C)}{P} \tag{69}$$

这个不等式满足有界差分条件。利用 McDiarmid 不等式 [McDiarmid et al., 1989]，对于任意 $\delta_1 > 0$，有至少 $1 - \delta_1$ 的概率有：

$$\Gamma(\mathbb{S}) \leq \mathbb{E}_{\mathbb{S}}[\Gamma(\mathbb{S})] + \omega_\Xi(C) \sqrt{\frac{\log(1/\delta_1)}{2P}} \tag{70}$$

这时候我们需要约束上式中的期望项 $\mathbb{E}_{\mathbb{S}}[\Gamma(\mathbb{S})]$。利用 $\mathbb{S}$ 和 $\mathbb{S}'$ 的关系，有：

$$\mathbb{E}_{\mathbb{S}}\left[\Gamma(\mathbb{S})\right] = \mathbb{E}_{\mathbb{S}}\left[\sup_{f \in \mathcal{H}}\left[\mathbb{E}_{\mathbb{S}'}\left[\frac{1}{P}\sum_{p=1}^{P} \mathcal{L}_{\mathrm{surr}}\left(f(\boldsymbol{u}'_p), \boldsymbol{a}'_p\right)\right] - \frac{1}{P}\sum_{p=1}^{P} \mathcal{L}_{\mathrm{surr}}\left(f(\boldsymbol{u}_p), \boldsymbol{a}_p\right)\right]\right] \tag{71}$$

$$\leq \mathbb{E}_{\mathbb{S}}\mathbb{E}_{\mathbb{S}'}\left[\sup_{f \in \mathcal{H}}\left[\frac{1}{P}\sum_{p=1}^{P}\left(\mathcal{L}_{\mathrm{surr}}\left(f(\boldsymbol{u}'_p), \boldsymbol{a}'_p\right) - \mathcal{L}_{\mathrm{surr}}\left(f(\boldsymbol{u}_p), \boldsymbol{a}_p\right)\right)\right]\right] \tag{72}$$

$$= \mathbb{E}_{\boldsymbol{\sigma}}\mathbb{E}_{\mathbb{S}}\mathbb{E}_{\mathbb{S}'}\left[\sup_{f \in \mathcal{H}}\left[\frac{1}{P}\sum_{p=1}^{P}\sigma_p\left(\mathcal{L}_{\mathrm{surr}}\left(f(\boldsymbol{u}'_p), \boldsymbol{a}'_p\right) - \mathcal{L}_{\mathrm{surr}}\left(f(\boldsymbol{u}_p), \boldsymbol{a}_p\right)\right)\right]\right] \tag{73}$$

$$\leq \mathbb{E}_{\boldsymbol{\sigma}}\left[\mathbb{E}_{\mathbb{S}}\left[\sup_{f \in \mathcal{H}}\left[\frac{1}{P}\sum_{p=1}^{P}\sigma_p\left(\mathcal{L}_{\mathrm{surr}}\left(f(\boldsymbol{u}_p), \boldsymbol{a}_p\right)\right)\right]\right] + \mathbb{E}_{\mathbb{S}}\left[\sup_{f \in \mathcal{H}}\left[\frac{1}{P}\sum_{p=1}^{P} -\sigma_p\left(\mathcal{L}_{\mathrm{surr}}\left(f(\boldsymbol{u}'_p), \boldsymbol{a}'_p\right)\right)\right]\right]\right] \tag{74}$$

$$\leq 2\mathbb{E}_{\boldsymbol{\sigma}}\mathbb{E}_{\mathbb{S}}\left[\sup_{f \in \mathcal{H}}\left[\frac{1}{P}\sum_{p=1}^{P}\sigma_p\left(\mathcal{L}_{\mathrm{surr}}\left(f(\boldsymbol{u}_p), \boldsymbol{a}_p\right)\right)\right]\right] \tag{75}$$

$$= 2\mathfrak{R}^P(\mathcal{L}_{\mathrm{surr}} \circ \mathcal{H}) \tag{76}$$

其中第一个不等号成立，是因为对于 $\sup(\cdot)$ 这样一个凸函数，先取 sup 再取期望要大于等于先取 sup 再取期望；第二个不等号成立是因为三角不等式。同时，注意到改变一个样本，$\hat{\mathfrak{R}}_P(\mathcal{L}_{\text{surr}} \circ \mathcal{H})$ 的变化最多为 $\frac{\omega_\Xi(C)}{P}$。再次应用 McDiarmid 不等式，对于任意 $\delta_2 > 0$，至少以 $1-\delta_2$ 概率有：

$$\mathfrak{R}^P(\mathcal{L}_{\text{surr}} \circ \mathcal{H}) = \mathbb{E}_{\mathbb{S}}[\hat{\mathfrak{R}}^P(\mathcal{L}_{\text{surr}} \circ \mathcal{H})] \tag{77}$$

$$\leq \hat{\mathfrak{R}}^P(\mathcal{L}_{\text{surr}} \circ \mathcal{H}) + \omega_\Xi(C)\sqrt{\frac{\log(1/\delta_2)}{2P}} \tag{78}$$

在 Theorem 2中，我们已经证明了 $\mathcal{L}_{\text{surr}}$ 的梯度上界是 C_μ，那么 L_{surr} 就是 C_μ-Lipschitz 的 [Boyd and Vandenberghe, 2004]。利用 Talagrand 不等式 [Talagrand, 1995, Mohri et al., 2018]，对于给定的样本集 $\mathbb{S}$，有：

$$\mathfrak{R}^P(\mathcal{L}_{\text{surr}} \circ \mathcal{H}) \leq C_\mu \cdot \mathfrak{R}^P(\mathcal{H}) \tag{79}$$

令 $\delta_1 = \delta_2 = \delta/2$，将 (79)代入 (77)，再连同 (71)一起代入 (70) 中，我们得到至少有 $1-\delta$ 的概率：

$$R_{\text{surr}}(f) \leq \hat{R}_{\text{surr}}(f) + 2C_\mu \cdot \hat{\mathfrak{R}}^P(\mathcal{H}) + 3\omega_\Xi(C)\sqrt{\frac{\log(2/\delta)}{2P}} \tag{80}$$

□

A.6 Corollary 1的证明

证明. 根据 Theorem 3，对于 $\forall\delta > 0$，有至少 $1-\delta$ 的概率，对于所有 $f \in \mathcal{H}$，经验替代风险与真实替代风险的最大偏差被界定为：$|R_{\text{surr}}(f;\mu) - \hat{R}_{\text{surr}}(f;\mu)| \leq 2C_\mu\hat{\mathfrak{R}}_P(\mathcal{H}) + 3\omega_\Xi(C)\sqrt{\frac{\log(2/\delta)}{2P}}$。同时，基于平滑近似误差的定义，对于任意 $f \in \mathcal{H}$ 恒有 $|R(f) - R_{\text{surr}}(f;\mu)| \leq \varphi(\mu)$。

为了评估训练所得模型 $\hat{f}_{P,\mu}$ 在真实场景中的表现，我们将真实替代风险 $R(\hat{f}_{P,\mu})$ 放缩：

$$\begin{aligned} R(\hat{f}_{P,\mu}) &\leq R_{\text{surr}}(\hat{f}_{P,\mu};\mu) + \varphi(\mu) \\ &\leq \hat{R}_{\text{surr}}(\hat{f}_{P,\mu};\mu) + 2C_\mu\hat{\mathfrak{R}}_P(\mathcal{H}) + 3\omega_\Xi(C)\sqrt{\frac{\log(2/\delta)}{2P}} + \varphi(\mu) \end{aligned} \tag{81}$$

由于 $\hat{f}_{P,\mu}$ 是经验替代风险的最小化预测函数，必有

$$\hat{R}_{\text{surr}}(\hat{f}_{P,\mu};\mu) \leq \hat{R}_{\text{surr}}(f^*;\mu) \tag{82}$$

将该不等式代入：

$$\begin{aligned} R(\hat{f}_{P,\mu}) &\leq \hat{R}_{\text{surr}}(f^*;\mu) + 2C_\mu\hat{\mathfrak{R}}_P(\mathcal{H}) + 3\omega_\Xi(C)\sqrt{\frac{\log(2/\delta)}{2P}} + \varphi(\mu) \\ &\leq R_{\text{surr}}(f^*;\mu) + 2C_\mu\hat{\mathfrak{R}}_P(\mathcal{H}) + 3\omega_\Xi(C)\sqrt{\frac{\log(2/\delta)}{2P}} + \varphi(\mu) \\ &\leq R(f^*) + 2C_\mu\hat{\mathfrak{R}}_P(\mathcal{H}) + 3\omega_\Xi(C)\sqrt{\frac{\log(2/\delta)}{2P}} + 2\varphi(\mu) \end{aligned} \tag{83}$$

当 $P \to \infty$ 时，统计泛化误差项 $2C_\mu\hat{\mathfrak{R}}_P(\mathcal{H}) + 3\omega_\Xi(C)\sqrt{\frac{\log(2/\delta)}{2P}} \to 0$；当 $\mu \to 0^+$ 时，根据内点法，log-barrier 问题的最优解严格逼近原 MIP 的最优解，因此最大近似偏差 $\varphi(\mu) \to 0$。因此，当 $P \to \infty$ 且 $\mu \to 0^+$ 时，不等式右侧的误差界趋于 0，即 $R(\hat{f}_{P,\mu})$ 以 $1-\delta$ 的概率收敛于理论最低真实风险 $R(f^*)$。这保证了最小化经验替代损失 $\hat{R}_{\text{surr}}$ 具备对真实业务损失 $\mathcal{L}$ 的 Fisher 一致性与校准性。

□

参考文献

A. Akbari, M. Awais, M. Bashar, and J. Kittler. How does loss function affect generalization performance of deep learning? application to human age estimation. In *International Conference on Machine Learning*, pages 141–151. PMLR, 2021.

Q. Berthet, M. Blondel, O. Teboul, M. Cuturi, J.-P. Vert, and F. Bach. Learning with differentiable pertubed optimizers. *Advances in Neural Information Processing Systems*, 33:9508–9519, 2020.

D. P. Bertsekas. Nonlinear programming. *Journal of the Operational Research Society*, 48(3):334–334, 1997.

S. Boyd and L. Vandenberghe. *Convex optimization*. Cambridge university press, 2004.

R. I. Cukier, H. Levine, and K. E. Shuler. Nonlinear sensitivity analysis of multiparameter model systems. *Journal of computational physics*, 26(1):1–42, 1978.

G. B. Dantzig. Linear programming. *Operations research*, 50(1):42–47, 2002.

T. K. Dey, A. N. Hirani, and B. Krishnamoorthy. Optimal homologous cycles, total unimodularity, and linear programming. In *Proceedings of the forty-second ACM symposium on Theory of computing*, pages 221–230, 2010.

R. M. Dudley. *Real analysis and probability*. Chapman and Hall/CRC, 2018.

O. El Balghiti, A. N. Elmachtoub, P. Grigas, and A. Tewari. Generalization bounds in the predict-then-optimize framework. *Mathematics of Operations Research*, 48(4):2043–2065, 2023.

A. N. Elmachtoub and P. Grigas. Smart "predict, then optimize". *Management Science*, 68(1):9–26, 2022.

K. Frisch. The logarithmic potential method of convex programming. *Memorandum, University Institute of Economics, Oslo*, 5(6), 1955.

T. Gal. *Postoptimal Analyses, Parametric Programming, and Related Topics: degeneracy, multicriteria decision making, redundancy*. Walter de Gruyter, 2010.

A. J. Hoffman. Total unimodularity and combinatorial theorems. *Linear Algebra and its Applications*, 13(1-2): 103–108, 1976.

X. Hu, J. Lee, and J. Lee. Two-stage predict+ optimize for milps with unknown parameters in constraints. *Advances in Neural Information Processing Systems*, 36:14247–14272, 2023.

H. Liu and P. Grigas. Risk bounds and calibration for a smart predict-then-optimize method. *Advances in Neural Information Processing Systems*, 34:22083–22094, 2021.

J. Mandi and T. Guns. Interior point solving for lp-based prediction+ optimisation. *Advances in Neural Information Processing Systems*, 33:7272–7282, 2020.

C. McDiarmid et al. On the method of bounded differences. *Surveys in combinatorics*, 141(1):148–188, 1989.

M. Mohri, A. Rostamizadeh, and A. Talwalkar. *Foundations of machine learning*. MIT press, 2018.

M. Talagrand. Concentration of measure and isoperimetric inequalities in product spaces. *Publications Mathématiques de l'Institut des Hautes Etudes Scientifiques*, 81(1):73–205, 1995.

J. Yang, E. Liang, Z. Su, Z. Zou, P. Zhen, J. Guo, W. Ma, and K. An. Dff: Decision-focused fine-tuning for smarter predict-then-optimize with limited data. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 39, pages 26868–26876, 2025.